支持向量机 SVM (下)

JerryLead

csxulijie@gmail.com

2011年3月17日星期四

7 核函数 (Kernels)

考虑我们最初在"线性回归"中提出的问题,特征是房子的面积 x,这里的 x 是实数,结果 y 是房子的价格。假设我们从样本点的分布中看到 x 和 y 符合 3 次曲线,那么我们希望使用 x 的三次多项式来逼近这些样本点。那么首先需要将特征 x 扩展到三维(x, x^2 , x^3),然后寻找特征和结果之间的模型。我们将这种特征变换称作特征映射(feature mapping)。映射函数称作 ϕ ,在这个例子中

$$\phi(\mathbf{x}) = \begin{bmatrix} x \\ x^2 \\ x^3 \end{bmatrix}$$

我们希望将得到的特征映射后的特征应用于 SVM 分类,而不是最初的特征。这样,我们需要将前面 $w^Tx + b$ 公式中的内积从< $x^{(i)},x>$,映射到< $\phi(x^{(i)}),\phi(x)>$ 。

至于为什么需要映射后的特征而不是最初的特征来参与计算,上面提到的(为了更好地拟合)是其中一个原因,另外的一个重要原因是样例可能存在线性不可分的情况,而将特征映射到高维空间后,往往就可分了。(在《数据挖掘导论》Pang-Ning Tan 等人著的《支持向量机》那一章有个很好的例子说明)

将核函数形式化定义,如果原始特征内积是< x, z >,映射后为 $< \phi(x), \phi(z) >$,那么定义核函数(Kernel)为

$$K(x,z) = \phi(x)^T \phi(z)$$

到这里,我们可以得出结论,如果要实现该节开头的效果,只需先计算 $\phi(x)$,然后计算 $\phi(x)^T\phi(z)$ 即可,然而这种计算方式是非常低效的。比如最初的特征是 n 维的,我们将其映射到 n^2 维,然后再计算,这样需要 $O(n^2)$ 的时间。那么我们能不能想办法减少计算时间呢?

先看一个例子, 假设 x 和 z 都是 n 维的,

$$K(x,z) = (x^T z)^2$$

展开后,得

$$K(x,z) = (x^T z)^2 = \left(\sum_{i=1}^n x_i z_i\right) \left(\sum_{j=1}^n x_j z_j\right) = \sum_{i=1}^n \sum_{j=1}^n x_i x_j z_i z_j$$
$$= \sum_{i=1}^n \sum_{j=1}^n (x_i x_j) (z_i z_j) = \phi(x)^T \phi(z)$$

这个时候发现我们可以只计算原始特征 x 和 z 内积的平方(时间复杂度是 O(n)),就等价与计算映射后特征的内积。也就是说我们不需要花 $O(n^2)$ 时间了。

现在看一下映射函数 (n=3 时), 根据上面的公式, 得到

$$\phi(x) = \begin{bmatrix} x_1 x_1 \\ x_1 x_2 \\ x_1 x_3 \\ x_2 x_1 \\ x_2 x_2 \\ x_2 x_3 \\ x_3 x_1 \\ x_3 x_2 \\ x_3 x_3 \end{bmatrix}$$

也就是说核函数 $K(x,z) = (x^Tz)^2$ 只能在选择这样的 ϕ 作为映射函数时才能够等价于映射后特征的内积。

再看一个核函数

$$K(x,z) = (x^{T}z + c)^{2}$$

$$= \sum_{i,j=1}^{n} (x_{i}x_{j})(z_{i}z_{j}) + \sum_{i=1}^{n} (\sqrt{2c}x_{i})(\sqrt{2c}z_{i}) + c^{2}.$$

对应的映射函数(n=3时)是

$$\phi(x) = \begin{bmatrix} x_1 x_1 \\ x_1 x_2 \\ x_1 x_3 \\ x_2 x_1 \\ x_2 x_2 \\ x_2 x_3 \\ x_3 x_1 \\ x_3 x_2 \\ x_3 x_3 \\ \sqrt{2c} x_1 \\ \sqrt{2c} x_2 \\ \sqrt{2c} x_3 \\ c \end{bmatrix},$$

更一般地,核函数 $K(x,z)=(x^Tz+c)^d$ 对应的映射后特征维度为 $\binom{\mathsf{n}+\mathsf{d}}{d}$ 。(这个我一直没有理解)。

由于计算的是内积,我们可以想到 IR 中的余弦相似度,如果 x 和 z 向量夹角越小,那么核函数值越大,反之,越小。因此,核函数值是 $\phi(x)$ 和 $\phi(z)$ 的相似度。

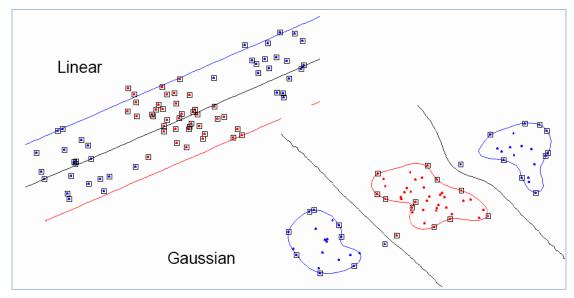
再看另外一个核函数

$$K(x,z) = \exp\left(-\frac{||x-z||^2}{2\sigma^2}\right).$$

这时,如果 x 和 z 很相近($||x-z|| \approx 0$),那么核函数值为 1,如果 x 和 z 相差很大($||x-z|| \gg 0$),那么核函数值约等于 0。由于这个函数类似于高斯分布,因此称为高斯核函数,也叫做径向基函数(Radial Basis Function 简称 RBF)。它能够把原始特征映射到无穷维。

既然高斯核函数能够比较 x 和 z 的相似度,并映射到 0 到 1,回想 logistic 回归,sigmoid 函数可以,因此还有 sigmoid 核函数等等。

下面有张图说明在低维线性不可分时,映射到高维后就可分了,使用高斯核函数。



来自 Eric Xing 的 slides

注意,使用核函数后,怎么分类新来的样本呢? 线性的时候我们使用 SVM 学习出 w 和 b,新来样本 x 的话,我们使用 w^T x + b来判断,如果值大于等于 1,那么是正类,小于等于是负类。在两者之间,认为无法确定。如果使用了核函数后, w^T x + b就变成了 $w^T\phi(x)$ + b,是否先要找到 $\phi(x)$,然后再预测? 答案肯定不是了,找 $\phi(x)$ 很麻烦,回想我们之前说过的

$$w^{T}x + b = \left(\sum_{i=1}^{m} \alpha_{i} y^{(i)} x^{(i)}\right)^{T} x + b$$
$$= \sum_{i=1}^{m} \alpha_{i} y^{(i)} \langle x^{(i)}, x \rangle + b.$$

只需将 $< x^{(i)}, x >$ 替换成 $K(x^{(i)}, x)$,然后值的判断同上。

8 核函数有效性判定

问题: 给定一个函数 K, 我们能否使用 K 来替代计算 $\phi(x)^T \phi(z)$, 也就说,是否能够找出一个 ϕ , 使得对于所有的 x 和 z, 都有 $K(x,z) = \phi(x)^T \phi(z)$?

比如给出了 $K(x,z) = (x^Tz)^2$,是否能够认为 K 是一个有效的核函数。

下面来解决这个问题,给定 m 个训练样本 $\{x^{(1)},x^{(2)},...,x^{(m)}\}$,每一个 $x^{(i)}$ 对应一个特征 向量。那么,我们可以将任意两个 $x^{(i)}$ 和 $x^{(j)}$ 带入 K 中,计算得到 $K_{ij}=K(x^{(i)},x^{(j)})$ 。I 可以从 1 到 m,j 可以从 1 到 m,这样可以计算出 m*m 的核函数矩阵(Kernel Matrix)。为了方便,我们将核函数矩阵和K(x,z)都使用 K 来表示。

如果假设 K 是有效的核函数,那么根据核函数定义

$$K_{ij} = K(x^{(i)}, x^{(j)}) = \phi(x^{(i)})^T \phi(x^{(j)}) = \phi(x^{(j)})^T \phi(x^{(i)}) = K(x^{(j)}, x^{(i)}) = K_{ii}$$

可见,矩阵 K 应该是个对称阵。让我们得出一个更强的结论,首先使用符号 $\phi_k(x)$ 来表示映射函数 $\phi(x)$ 的第 k 维属性值。那么对于任意向量 z,得

$$z^{T}Kz = \sum_{i} \sum_{j} z_{i}K_{ij}z_{j}$$

$$= \sum_{i} \sum_{j} z_{i}\phi(x^{(i)})^{T}\phi(x^{(j)})z_{j}$$

$$= \sum_{i} \sum_{j} z_{i} \sum_{k} \phi_{k}(x^{(i)})\phi_{k}(x^{(j)})z_{j}$$

$$= \sum_{k} \sum_{i} \sum_{j} z_{i}\phi_{k}(x^{(i)})\phi_{k}(x^{(j)})z_{j}$$

$$= \sum_{k} \left(\sum_{i} z_{i}\phi_{k}(x^{(i)})\right)^{2}$$

$$\geq 0.$$

最后一步和前面计算 $K(x,z)=(x^Tz)^2$ 时类似。从这个公式我们可以看出,如果 K 是个有效的核函数(即K(x,z)和 $\phi(x)^T\phi(z)$ 等价),那么,在训练集上得到的核函数矩阵 K 应该是半正定的(K \geq 0)

这样我们得到一个核函数的必要条件:

K 是有效的核函数 ==> 核函数矩阵 K 是对称半正定的。

可幸的是,这个条件也是充分的,由 Mercer 定理来表达。

Mercer 定理:

如果函数 $K \in \mathbb{R}^n \times \mathbb{R}^n \to \mathbb{R}$ 上的映射(也就是从两个 n 维向量映射到实数域)。那么如果 K 是一个有效核函数(也称为 Mercer 核函数),那么当且仅当对于训练样例 $\{x^{(1)}, x^{(2)}, ..., x^{(m)}\}$,其相应的核函数矩阵是对称半正定的。

Mercer 定理表明为了证明 K 是有效的核函数,那么我们不用去寻找 ϕ ,而只需要在训练集上求出各个 K_{ij} ,然后判断矩阵 K 是否是半正定(使用左上角主子式大于等于零等方法)即可。

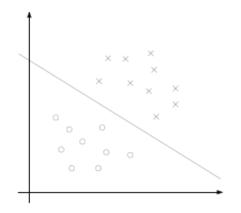
许多其他的教科书在 Mercer 定理证明过程中使用了 L^2 范数和再生希尔伯特空间等概念,但在特征是n维的情况下,这里给出的证明是等价的。

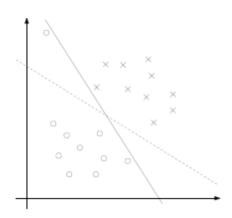
核函数不仅仅用在 SVM 上,但凡在一个模型后算法中出现了< x, z >,我们都可以常使用K(x,z)去替换,这可能能够很好地改善我们的算法。

9 规则化和不可分情况处理 (Regularization and the non-separable case)

我们之前讨论的情况都是建立在样例线性可分的假设上,当样例线性不可分时,我们可以尝试使用核函数来将特征映射到高维,这样很可能就可分了。然而,映射后我们也不能 100%保证可分。那怎么办呢,我们需要将模型进行调整,以保证在不可分的情况下,也能够尽可能地找出分隔超平面。

看下面两张图:





可以看到一个离群点(可能是噪声)可以造成超平面的移动,间隔缩小,可见以前的模型对噪声非常敏感。再有甚者,如果离群点在另外一个类中,那么这时候就是线性不可分了。

这时候我们应该允许一些点游离并在在模型中违背限制条件(函数间隔大于 1)。我们设计得到新的模型如下(也称软间隔):

$$\min_{\gamma, w, b} \frac{1}{2} ||w||^2 + C \sum_{i=1}^m \xi_i$$
s.t. $y^{(i)}(w^T x^{(i)} + b) \ge 1 - \xi_i, \quad i = 1, \dots, m$
 $\xi_i \ge 0, \quad i = 1, \dots, m.$

引入非负参数 ξ_i 后(称为松弛变量),就允许某些样本点的函数间隔小于 1,即在最大间隔区间里面,或者函数间隔是负数,即样本点在对方的区域中。而放松限制条件后,我们需要重新调整目标函数,以对离群点进行处罚,目标函数后面加上的 $C\sum_{i=1}^m \xi_i$ 就表示离群点越多,目标函数值越大,而我们要求的是尽可能小的目标函数值。这里的 C 是离群点的权重,C 越大表明离群点对目标函数影响越大,也就是越不希望看到离群点。我们看到,目标函数控制了离群点的数目和程度,使大部分样本点仍然遵守限制条件。

模型修改后,拉格朗日公式也要修改如下:

$$\mathcal{L}(w, b, \xi, \alpha, r) = \frac{1}{2}w^T w + C \sum_{i=1}^m \xi_i - \sum_{i=1}^m \alpha_i \left[y^{(i)}(x^T w + b) - 1 + \xi_i \right] - \sum_{i=1}^m r_i \xi_i.$$

这里的 α_i 和 γ_i 都是拉格朗日乘子,回想我们在拉格朗日对偶中提到的求法,先写出拉格朗日公式(如上),然后将其看作是变量 w 和 b 的函数,分别对其求偏导,得到 w 和 b 的表达式。然后代入公式中,求带入后公式的极大值。整个推导过程类似以前的模型,这里只写出最后结果如下:

$$\max_{\alpha} W(\alpha) = \sum_{i=1}^{m} \alpha_i - \frac{1}{2} \sum_{i,j=1}^{m} y^{(i)} y^{(j)} \alpha_i \alpha_j \langle x^{(i)}, x^{(j)} \rangle$$
s.t. $0 \le \alpha_i \le C, \quad i = 1, \dots, m$

$$\sum_{i=1}^{m} \alpha_i y^{(i)} = 0,$$

此时,我们发现没有了参数 ξ_i ,与之前模型唯一不同在于 α_i 又多了 $\alpha_i \leq C$ 的限制条件。需要提醒的是,b 的求值公式也发生了改变,改变结果在 SMO 算法里面介绍。先看看 KKT

条件的变化:

$$\alpha_i = 0 \implies y^{(i)}(w^T x^{(i)} + b) \ge 1$$
 (14)

$$\alpha_i = C \Rightarrow y^{(i)}(w^T x^{(i)} + b) \le 1$$
 (15)

$$0 < \alpha_i < C \implies y^{(i)}(w^T x^{(i)} + b) = 1.$$
 (16)

第一个式子表明在两条间隔线外的样本点前面的系数为 0, 离群样本点前面的系数为 C, 而支持向量(也就是在超平面两边的最大间隔线上)的样本点前面系数在(0,C)上。通过 KKT 条件可知,某些在最大间隔线上的样本点也不是支持向量,相反也可能是离群点。

10 坐标上升法(Coordinate ascent)

在最后讨论 $W(\alpha)$ 的求解之前,我们先看看坐标上升法的基本原理。假设要求解下面的优化问题:

$$\max_{\alpha} W(\alpha_1, \alpha_2, \dots, \alpha_m).$$

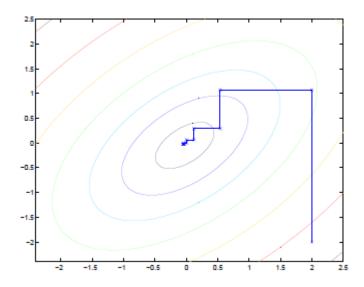
这里 W 是 α 向量的函数。之前我们在回归中提到过两种求最优解的方法,一种是梯度下降法,另外一种是牛顿法。现在我们再讲一种方法称为坐标上升法(求解最小值问题时,称作坐标下降法,原理一样)。

方法过程:

```
Loop until convergence: {  \text{For } i=1,\ldots,m, \ \{ \\ \alpha_i:=\arg\max_{\hat{\alpha}_i}W(\alpha_1,\ldots,\alpha_{i-1},\hat{\alpha}_i,\alpha_{i+1},\ldots,\alpha_m).  } }
```

最里面语句的意思是固定除 α_i 之外的所有 $\alpha_j(j \neq i)$,这时 W 可看作只是关于 α_i 的函数,那么直接对 α_i 求导优化即可。这里我们进行最大化求导的顺序 i 是从 1 到 m,可以通过更改优化顺序来使 W 能够更快地增加并收敛。如果 W 在内循环中能够很快地达到最优,那么坐标上升法会是一个很高效的求极值方法。

下面通过一张图来展示:



椭圆代表了二次函数的各个等高线,变量数为 2,起始坐标是(2,-2)。图中的直线式迭代优化的路径,可以看到每一步都会向最优值前进一步,而且前进路线是平行于坐标轴的,因为每一步只优化一个变量。

11 SMO 优化算法(Sequential minimal optimization)

SMO 算法由 Microsoft Research 的 John C. Platt 在 1998 年提出,并成为最快的二次规划优化算法,特别针对线性 SVM 和数据稀疏时性能更优。关于 SMO 最好的资料就是他本人写的《Sequential Minimal Optimization A Fast Algorithm for Training Support Vector Machines》了。

我拜读了一下,下面先说讲义上对此方法的总结。

首先回到我们前面一直悬而未解的问题,对偶函数最后的优化问题:

$$\max_{\alpha} W(\alpha) = \sum_{i=1}^{m} \alpha_i - \frac{1}{2} \sum_{i,j=1}^{m} y^{(i)} y^{(j)} \alpha_i \alpha_j \langle x^{(i)}, x^{(j)} \rangle$$

s.t. $0 \le \alpha_i \le C, \quad i = 1, \dots, m$
$$\sum_{i=1}^{m} \alpha_i y^{(i)} = 0,$$

要解决的是在参数 $\{\alpha_1,\alpha_2,...,\alpha_n\}$ 上求最大值 W 的问题,至于 $x^{(i)}$ 和 $y^{(i)}$ 都是已知数。C 由我们预先设定,也是已知数。

按照坐标上升的思路,我们首先固定除 α_1 以外的所有参数,然后在 α_1 上求极值。等一下,这个思路有问题,因为如果固定 α_1 以外的所有参数,那么 α_1 将不再是变量(可以由其他值推出),因为问题中规定了

$$\alpha_1 y^{(1)} = -\sum_{i=2}^m \alpha_i y^{(i)}.$$

因此,我们需要一次选取两个参数做优化,比如 α_1 和 α_2 ,此时 α_2 可以由 α_1 和其他参数表示出来。这样回带到 W 中,W 就只是关于 α_1 的函数了,可解。

这样, SMO 的主要步骤如下:

Repeat till convergence {

- Select some pair α_i and α_j to update next (using a heuristic that tries to pick the two that will allow us to make the biggest progress towards the global maximum).
- 2. Reoptimize $W(\alpha)$ with respect to α_i and α_j , while holding all the other α_k 's $(k \neq i, j)$ fixed.

}

意思是,第一步选取一对 α_i 和 α_j ,选取方法使用启发式方法(后面讲)。第二步,固定除 α_i 和 α_i 之外的其他参数,确定 W 极值条件下的 α_i , α_i 由 α_i 表示。

SMO 之所以高效就是因为在固定其他参数后,对一个参数优化过程很高效。 下面讨论具体方法:

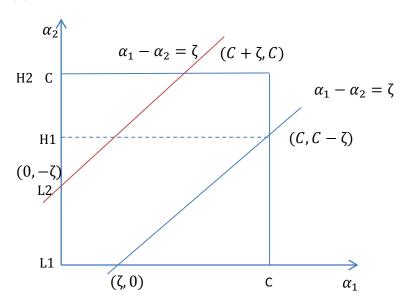
假设我们选取了初始值 $\{\alpha_1,\alpha_2,...,\alpha_n\}$ 满足了问题中的约束条件。接下来,我们固定 $\{\alpha_3,\alpha_4,...,\alpha_n\}$,这样 W 就是 α_1 和 α_2 的函数。并且 α_1 和 α_2 满足条件:

$$\alpha_1 y^{(1)} + \alpha_2 y^{(2)} = -\sum_{i=3}^{m} \alpha_i y^{(i)}.$$

由于 $\{\alpha_3, \alpha_4, ..., \alpha_n\}$ 都是已知固定值,因此为了方面,可将等式右边标记成实数值 ζ 。

$$\alpha_1 y^{(1)} + \alpha_2 y^{(2)} = \zeta.$$

当 $y^{(1)}$ 和 $y^{(2)}$ 异号时,也就是一个为 1,一个为-1 时,他们可以表示成一条直线,斜率为 1。如下图:



横轴是 α_1 ,纵轴是 α_2 , α_1 和 α_2 既要在矩形方框内,也要在直线上,因此

$$L = max(0, \alpha_2 - \alpha_1), H = min(C, C + \alpha_2 - \alpha_1)$$

同理, 当y⁽¹⁾和y⁽²⁾同号时,

$$L = max(0, \alpha_2 + \alpha_1 - C), H = min(C, \alpha_2 + \alpha_1)$$

然后我们打算将 α_1 用 α_2 表示:

$$\alpha_1 = (\zeta - \alpha_2 y^{(2)}) y^{(1)}.$$

然后反代入 W 中,得

$$W(\alpha_1, \alpha_2, \dots, \alpha_m) = W((\zeta - \alpha_2 y^{(2)}) y^{(1)}, \alpha_2, \dots, \alpha_m).$$

展开后 W 可以表示成 $a{\alpha_2}^2 + b{\alpha_2} + c$ 。其中 a,b,c 是固定值。这样,通过对 W 进行求导可以得到 α_2 ,然而要保证 α_2 满足L $\leq \alpha_2 \leq H$,我们使用 $\alpha_2^{new,unclipped}$ 表示求导求出来的 α_2 ,然而最后的 α_2 ,要根据下面情况得到:

$$\alpha_2^{\textit{new}} \ = \ \left\{ \begin{array}{ll} H & \text{if } \alpha_2^{\textit{new}, \textit{unclipped}} > H \\ \alpha_2^{\textit{new}, \textit{unclipped}} & \text{if } L \leq \alpha_2^{\textit{new}, \textit{unclipped}} \leq H \\ L & \text{if } \alpha_2^{\textit{new}, \textit{unclipped}} < L \end{array} \right.$$

这样得到 α_2^{new} 后,我们可以得到 α_1 的新值 α_1^{new} 。

下面进入 Platt 的文章,来找到启发式搜索的方法和求 b 值的公式。

这篇文章使用的符号表示有点不太一样,不过实质是一样的,先来熟悉一下文章中符号的表示。

文章中定义特征到结果的输出函数为

$$u = \vec{w} \cdot \vec{x} - b, \tag{1}$$

与我们之前的 $w^T x^{(i)} + b$ 实质是一致的。 原始的优化问题为:

$$\min_{\vec{w}, b} \frac{1}{2} ||\vec{w}||^2 \text{ subject to } y_i(\vec{w} \cdot \vec{x}_i - b) \ge 1, \forall i,$$
 (3)

求导得到:

$$\vec{w} = \sum_{i=1}^{N} y_i \alpha_i \vec{x}_i, \quad b = \vec{w} \cdot \vec{x}_k - y_k \text{ for some } \alpha_k > 0.$$
 (7)

经过对偶后为:

$$\min_{\vec{\alpha}} \Psi(\vec{\alpha}) = \min_{\vec{\alpha}} \frac{1}{2} \sum_{i=1}^{N} \sum_{j=1}^{N} y_i y_j (\vec{x}_i \cdot \vec{x}_j) \alpha_i \alpha_j - \sum_{i=1}^{N} \alpha_i,$$

$$\alpha_i \geq 0, \forall i,$$

$$\sum_{i=1}^{N} y_i \alpha_i = 0.$$

这里与 W 函数是一样的,只是符号求反后,变成求最小值了。 y_i 和 $y^{(i)}$ 是一样的,都表示第 i 个样本的输出结果(1 或-1)。

经过加入松弛变量 ξ_i 后,模型修改为:

$$\min_{\vec{w}, b, \vec{\xi}} \frac{1}{2} ||\vec{w}||^2 + C \sum_{i=1}^{N} \xi_i \quad \text{subject to } y_i (\vec{w} \cdot \vec{x}_i - b) \ge 1 - \xi_i, \forall i,$$
 (8)

$$0 \le \alpha_i \le C, \forall i. \tag{9}$$

由公式(7)代入(1)中可知,

$$u = \sum_{i=1}^{N} y_{j} \alpha_{j} K(\vec{x}_{j}, \vec{x}) - b,$$
 (10)

这个过程和之前对偶过程一样。 重新整理我们要求的问题为:

$$\min_{\alpha} \Psi(\vec{\alpha}) = \min_{\alpha} \frac{1}{2} \sum_{i=1}^{N} \sum_{j=1}^{N} y_i y_j K(\vec{x}_i, \vec{x}_j) \alpha_i \alpha_j - \sum_{i=1}^{N} \alpha_i,
0 \le \alpha_i \le C, \forall i,
\sum_{i=1}^{N} y_i \alpha_i = 0.$$
(11)

与之对应的 KKT 条件为:

$$\alpha_i = 0 \Leftrightarrow y_i u_i \ge 1,$$
 $0 < \alpha_i < C \Leftrightarrow y_i u_i = 1,$
 $\alpha_i = C \Leftrightarrow y_i u_i \le 1.$
(12)

这个 KKT 条件说明,在两条间隔线外面的点,对应前面的系数 α_i 为 0,在两条间隔线里面的对应 α_i 为 C,在两条间隔线上的对应的系数 α_i 在 0 和 C 之间。

将我们之前得到 L 和 H 重新拿过来:

$$L = \max(0, \alpha_2 - \alpha_1), \qquad H = \min(C, C + \alpha_2 - \alpha_1).$$
 (13)

$$L = \max(0, \alpha_2 + \alpha_1 - C), \qquad H = \min(C, \alpha_2 + \alpha_1). \tag{14}$$

之前我们将问题进行到这里,然后说将 α_1 用 α_2 表示后代入W中,这里将代入 Ψ 中,得

$$K_{ij} = K(\vec{x}_i, \vec{x}_j),$$

$$v_i = \sum_{j=3}^{N} y_j \alpha_j^* K_{ij} = u_i + b^* - y_1 \alpha_1^* K_{1i} - y_2 \alpha_2^* K_{2i},$$
(25)

这里的 α_1 *和 α_2 *代表某次迭代前的原始值,因此是常数,而 α_1 和 α_2 是变量,待求。公式(24)中的最后一项是常数。

由于 α_1 和 α_2 满足以下公式

$$y_1 \alpha_1^* + y_2 \alpha_2^* = -\sum_{i=3}^n y_i \alpha_i^* = y_1 \alpha_1 + y_2 \alpha_2$$

因为 α_i^* (i > 2)的值是固定值,在迭代前后不会变。那么用 s 表示 y_1y_2 ,上式两边乘以 y_1 时,变为:

$$\alpha_1 + s\alpha_2 = \alpha_1^* + s\alpha_2^* = w. \tag{26}$$

其中

$$w = -y_1 \sum_{i=3}^n y_i \alpha_i^*$$

代入(24)中,得

$$\Psi = \frac{1}{2} K_{11} (w - s\alpha_2)^2 + \frac{1}{2} K_{22} \alpha_2^2 + sK_{12} (w - s\alpha_2) \alpha_2
+ y_1 (w - s\alpha_2) v_1 - w + s\alpha_2 + y_2 \alpha_2 v_2 - \alpha_2 + \Psi_{\text{constant}}.$$
(27)

这时候只有 α_2 是变量了,求导

$$\frac{d\Psi}{d\alpha_2} = -sK_{11}(w - s\alpha_2) + K_{22}\alpha_2 - K_{12}\alpha_2 + sK_{12}(w - s\alpha_2) - y_2v_1 + s + y_2v_2 - 1 = 0.$$
 (28)

如果Ψ的二阶导数大于 0 (凹函数),那么一阶导数为 0 时,就是极小值了。假设其二阶导数为 0 (一般成立),那么上式化简为:

$$\alpha_2(K_{11} + K_{22} - 2K_{12}) = s(K_{11} - K_{12}) w + y_2(v_1 - v_2) + 1 - s.$$
(29)

将 w 和 v 代入后,继续化简推导,得(推导了六七行推出来了)

$$\alpha_2(K_{11} + K_{22} - 2K_{12}) = \alpha_2^*(K_{11} + K_{22} - 2K_{12}) + y_2(u_1 - u_2 + y_2 - y_1). \tag{30}$$

我们使用η来表示:

$$\eta = K(\vec{x}_1, \vec{x}_1) + K(\vec{x}_2, \vec{x}_2) - 2K(\vec{x}_1, \vec{x}_2). \tag{15}$$

通常情况下目标函数是正定的,也就是说,能够在直线约束方向上求得最小值,并且 $\eta > 0$ 。

那么我们在(30)两边都除以n可以得到

$$\alpha_2^{\text{new}} = \alpha_2 + \frac{y_2(E_1 - E_2)}{\eta},$$
(16)

这里我们使用 α_2^{new} 表示优化后的值, α_2 是迭代前的值, $E_i = u_i - y_i$ 。与之前提到的一样 α_2^{new} 不是最终迭代后的值,需要进行约束:

$$\alpha_{2}^{\text{new,clipped}} = \begin{cases} H & \text{if} & \alpha_{2}^{\text{new}} \ge H; \\ \alpha_{2}^{\text{new}} & \text{if} & L < \alpha_{2}^{\text{new}} < H; \\ L & \text{if} & \alpha_{2}^{\text{new}} \le L. \end{cases}$$
(17)

$$\alpha_1^{\text{new}} = \alpha_1 + s(\alpha_2 - \alpha_2^{\text{new,clipped}}). \tag{18}$$

在特殊情况下, η 可能不为正,如果核函数 K 不满足 Mercer 定理,那么目标函数可能变得非正定, η 可能出现负值。即使 K 是有效的核函数,如果训练样本中出现相同的特征 x,那么 η 仍有可能为 0。SMO 算法在 η 不为正值的情况下仍有效。为保证有效性,我们可以推导出 η 就是 Ψ 的二阶导数, η < 0, Ψ 没有极小值,最小值在边缘处取到(类比 $y=-x^2$), $\eta=0$ 时更是单调函数了,最小值也在边缘处取得,而 α_2 的边缘就是 L 和 H。这样将 $\alpha_2=L$ 和 $\alpha_2=H$ 分别代入 Ψ 中即可求得 Ψ 的最小值,相应的 $\alpha_2=L$ 还是 $\alpha_2=H$ 也可以知道了。具体计算公式如下:

$$f_{1} = y_{1}(E_{1} + b) - \alpha_{1}K(\vec{x}_{1}, \vec{x}_{1}) - s\alpha_{2}K(\vec{x}_{1}, \vec{x}_{2}),$$

$$f_{2} = y_{2}(E_{2} + b) - s\alpha_{1}K(\vec{x}_{1}, \vec{x}_{2}) - \alpha_{2}K(\vec{x}_{2}, \vec{x}_{2}),$$

$$L_{1} = \alpha_{1} + s(\alpha_{2} - L),$$

$$H_{1} = \alpha_{1} + s(\alpha_{2} - H),$$

$$\Psi_{L} = L_{1}f_{1} + Lf_{2} + \frac{1}{2}L_{1}^{2}K(\vec{x}_{1}, \vec{x}_{1}) + \frac{1}{2}L^{2}K(\vec{x}_{2}, \vec{x}_{2}) + sLL_{1}K(\vec{x}_{1}, \vec{x}_{2}),$$

$$\Psi_{H} = H_{1}f_{1} + Hf_{2} + \frac{1}{2}H_{1}^{2}K(\vec{x}_{1}, \vec{x}_{1}) + \frac{1}{2}H^{2}K(\vec{x}_{2}, \vec{x}_{2}) + sHH_{1}K(\vec{x}_{1}, \vec{x}_{2}).$$

$$(19)$$

至此, 迭代关系式除了 b 的推导式以外, 都已经推出。

b 每一步都要更新,因为前面的 KKT 条件指出了 α_i 和 y_iu_i 的关系,而 u_i 和 b 有关,在每一步计算出 α_i 后,根据 KKT 条件来调整 b。

b 的更新有几种情况:

b的更新:选择b使得关于乘子 α ,或 α ,的KKT条件成立

$$b_1 = E_1 + y_1(\alpha_1^{new} - \alpha_1)k(x_1, x_1) + y_2(\alpha_2^{new, clipped} - \alpha_2)k(x_1, x_2) + b \quad (7)$$

$$b_2 = E_2 + y_1(\alpha_1^{new} - \alpha_1)k(x_1, x_2) + y_2(\alpha_2^{new, clipped} - \alpha_2)k(x_2, x_2) + b$$
 (8)

如果 α_1^{new} 在界内,则 $b^{\text{new}} = b_1$;如果 $\alpha_2^{\text{new},\text{clipped}}$ 在界内, $b^{\text{new}} = b_2$;

如果 α_1^{new} 和 $\alpha_2^{new,clipped}$ 都在界内,那么 $b_1 = b_2$,则 $b^{new} = b_1 = b_2$;

如果 α_1^{new} 和 $\alpha_2^{new,clipped}$ 都在界上,那么 b_1 和 b_2 之间的任何数都满足 KKT条件,都可作为b的更新值,一般取 $b^{new} = (b_1 + b_2)/2$.

来自罗林开的 ppt

这里的界内指 $0 < \alpha_i < C$,界上就是等于0或者C了。前面两个的公式推导可以根据

$$y_1 \alpha_1^* + y_2 \alpha_2^* = -\sum_{i=3}^n y_i \alpha_i^* = y_1 \alpha_1 + y_2 \alpha_2^*$$

和对于 $0 < \alpha_i < C$ 有 $y_i u_i = 1$ 的 KKT 条件推出。

这样全部参数的更新公式都已经介绍完毕,附加一点,如果使用的是线性核函数,我们就可以继续使用 w 了,这样不用扫描整个样本库来作内积了。

w 值的更新方法为:

$$\vec{w}^{\text{new}} = \vec{w} + y_1 (\alpha_1^{\text{new}} - \alpha_1) \vec{x}_1 + y_2 (\alpha_2^{\text{new,clipped}} - \alpha_2) \vec{x}_2.$$
 (22)

根据前面的

$$\vec{w} = \sum_{i=1}^{N} y_i \alpha_i \vec{x}_i, \quad b = \vec{w} \cdot \vec{x}_k - y_k \text{ for some } \alpha_k > 0.$$
 (7)

公式推导出。

12 SMO 中拉格朗日乘子的启发式选择方法

终于到了最后一个问题了,所谓的启发式选择方法主要思想是每次选择拉格朗日乘子的时候,优先选择样本前面系数 $0 < \alpha_i < C$ 的 α_i 作优化(论文中称为无界样例),因为在界上(α_i 为0或C)的样例对应的系数 α_i 一般不会更改。

这条启发式搜索方法是选择第一个拉格朗日乘子用的,比如前面的 α_2 。那么这样选择的话,是否最后会收敛?可幸的是 Osuna 定理告诉我们只要选择出来的两个 α_i 中有一个违背了 KKT 条件,那么目标函数在一步迭代后值会减小。违背 KKT 条件不代表 $0 < \alpha_i < C$,在界上也有可能会违背。是的,因此在给定初始值 α_i =0 后,先对所有样例进行循环,循环中碰到违背 KKT 条件的(不管界上还是界内)都进行迭代更新。等这轮过后,如果没有收敛,第二轮就只针对 $0 < \alpha_i < C$ 的样例进行迭代更新。

在第一个乘子选择后,第二个乘子也使用启发式方法选择,第二个乘子的迭代步长大致正比于 $|E_1-E_2|$,选择第二个乘子能够最大化 $|E_1-E_2|$ 。即当 E_1 为正时选择负的绝对值最大的 E_2 ,反之,选择正值最大的 E_2 。

最后的收敛条件是在界内($0 < \alpha_i < C$)的样例都能够遵循 KKT 条件,且其对应的 α_i 只在极小的范围内变动。

至于如何写具体的程序,请参考 John C. Platt 在论文中给出的伪代码。

13 总结

这份 SVM 的讲义重点概括了 SVM 的基本概念和基本推导,中规中矩却又让人醍醐灌顶。起初让我最头疼的是拉格朗日对偶和 SMO,后来逐渐明白拉格朗日对偶的重要作用是将 w的计算提前并消除 w,使得优化函数变为拉格朗日乘子的单一参数优化问题。而 SMO 里面迭代公式的推导也着实让我花费了不少时间。

对比这么复杂的推导过程,SVM 的思想确实那么简单。它不再像 logistic 回归一样企图 去拟合样本点(中间加了一层 sigmoid 函数变换),而是就在样本中去找分隔线,为了评判 哪条分界线更好,引入了几何间隔最大化的目标。

之后所有的推导都是去解决目标函数的最优化上了。在解决最优化的过程中,发现了w可以由特征向量内积来表示,进而发现了核函数,仅需要调整核函数就可以将特征进行低维到高维的变换,在低维上进行计算,实质结果表现在高维上。由于并不是所有的样本都可分,为了保证 SVM 的通用性,进行了软间隔的处理,导致的结果就是将优化问题变得更加复杂,然而惊奇的是松弛变量没有出现在最后的目标函数中。最后的优化求解问题,也被拉格朗日对偶和 SMO 算法化解,使 SVM 趋向于完美。

另外,其他很多议题如 SVM 背后的学习理论、参数选择问题、二值分类到多值分类等等还没有涉及到,以后有时间再学吧。其实朴素贝叶斯在分类二值分类问题时,如果使用对数比,那么也算作线性分类器。